

Carregando as Bibliotecas Necessárias

```
In [15]: # Importando as Bibliotecas
import pandas as pd
import matplotlib.pyplot as plt

import seaborn as sns
from seaborn import load_dataset

import numpy as np

import statsmodels.formula.api as smf
```

In []:

Regressão 01 - tarefa 01

```
In [16]: # A base dados será uma base da própria biblioteca do seaborn que seria o do

tips = sns.load_dataset("tips")
tips['net_bill'] = tips['total_bill'] - tips['tip']
tips['tip_pct'] = tips['tip'] / tips['net_bill']
tips.drop(['total_bill', 'sex', 'smoker', 'day', 'time', 'size'], axis=1, in
tips.head()
```

Out[16]:

	tip	net_bill	tip_pct
0	1.01	15.98	0.063204
1	1.66	8.68	0.191244
2	3.50	17.51	0.199886
3	3.31	20.37	0.162494
4	3.61	20.98	0.172069

In []:

1. Explorando a base de gorjetas

a. Na aula fizemos uma regressão de `tip` explicada por `net_bill`. Carregue os pacotes e a base, crie as variáveis necessárias como na aula, e reproduza esta regressão.

b. Reproduza também o gráfico de dispersão dessas duas variáveis.

In []:

a.a. Na aula fizemos uma regressão de `tip` explicada por `net_bill`. Carregue os pacotes e a base, crie as variáveis necessárias como na aula, e reproduza esta regressão.

```
In [17]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.formula.api as smf

gorjetas = sns.load_dataset('tips')

gorjetas['net_bill'] = gorjetas['total_bill'] - gorjetas['tip']

gorjetas.head()
```

```
Out[17]:
```

	total_bill	tip	sex	smoker	day	time	size	net_bill
0	16.99	1.01	Female	No	Sun	Dinner	2	15.98
1	10.34	1.66	Male	No	Sun	Dinner	3	8.68
2	21.01	3.50	Male	No	Sun	Dinner	3	17.51
3	23.68	3.31	Male	No	Sun	Dinner	2	20.37
4	24.59	3.61	Female	No	Sun	Dinner	4	20.98

```
In [18]: modelo = smf.ols('tip ~ net_bill', data=gorjetas).fit()

modelo.summary()
```

```
Out[18]:
```

OLS Regression Results

Dep. Variable:	tip	R-squared:	0.333
Model:	OLS	Adj. R-squared:	0.330
Method:	Least Squares	F-statistic:	120.6
Date:	Wed, 01 Apr 2026	Prob (F-statistic):	5.02e-23
Time:	00:37:11	Log-Likelihood:	-375.63
No. Observations:	244	AIC:	755.3
Df Residuals:	242	BIC:	762.3
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	1.3307	0.168	7.907	0.000	0.999	1.662
net_bill	0.0993	0.009	10.980	0.000	0.082	0.117

Omnibus:	33.873	Durbin-Watson:	2.123
Prob(Omnibus):	0.000	Jarque-Bera (JB):	59.942
Skew:	0.754	Prob(JB):	9.63e-14
Kurtosis:	4.903	Cond. No.	43.3


Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

b. Reproduza também o gráfico de dispersão dessas duas variáveis.

```
In [19]: # Gráfico de dispersão 'tip x net_bill'.
```

```
In [20]: sns.scatterplot(x='net_bill', y='tip', data=gorjetas)
plt.show()
```



2. Mudança de perspectiva

Agora ajuste um modelo de regressão de `tip_pct` por `net_bill`. Construa o gráfico de dispersão correspondente.

```
In [ ]:
```

Resolvendo item 2

```
In [23]: gorjetas['tip_pct'] = gorjetas['tip'] / gorjetas['net_bill']
```

In [24]:

```
# Código da regressão:
modelo_tip_pct = smf.ols('tip_pct ~ net_bill', data=gorjetas).fit()

modelo_tip_pct.summary()
```

Out[24]:

OLS Regression Results

Dep. Variable:	tip_pct	R-squared:	0.091
Model:	OLS	Adj. R-squared:	0.088
Method:	Least Squares	F-statistic:	24.31
Date:	Wed, 01 Apr 2026	Prob (F-statistic):	1.52e-06
Time:	00:38:55	Log-Likelihood:	108.00
No. Observations:	244	AIC:	-212.0
Df Residuals:	242	BIC:	-205.0
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	0.3053	0.023	13.166	0.000	0.260	0.351
net_bill	-0.0061	0.001	-4.931	0.000	-0.009	-0.004


Omnibus:	468.674	Durbin-Watson:	1.987
Prob(Omnibus):	0.000	Jarque-Bera (JB):	234437.604
Skew:	11.104	Prob(JB):	0.00
Kurtosis:	153.221	Cond. No.	43.3

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

In [25]: *#Gráfico de dispersão:*

```
sns.scatterplot(x='net_bill', y='tip_pct', data=gorjetas)
plt.show()
```



3. Comente

Compare os dois gráficos e comente (de forma objetiva e sucinta) a relação entre eles e a diferença do ajuste. Podemos comparar diretamente os R^2 s?

Type *Markdown* and LaTeX: α^2

In []:

4. Ajuste do modelo em outra escala

Com o modelo no item 3, obtenha a preditiva do valor da gorjeta:

1. obtenha o valor predito `pred` para `tip_pct` (dica, veja o atributo `reg.fittedvalues`)
2. obtenha o valor predito para `tip` como `tip_pct * net_bill`
3. calcule o R^2 do modelo para `tip`
4. compare esse R^2 com o do item 1

In []:

In []: